

Machine Learning in Particle Physics

Correzione alle Energie di Raggi Cosmici

Roberto Di Loreto

Università degli Studi dell'Aquila

July 28, 2026

Lo scopo di questo progetto è quello di mostrare come i metodi di Machine Learning (ML) possano aiutare a comprendere meglio la fisica che si cela dietro i *raggi cosmici*.

L'idea è analizzare i dati del Pierre Auger Observatory per studiare la ricostruzione dell'energia dei raggi cosmici. Queste particelle trasportano energie milioni di volte superiori a quelle raggiungibili al Large Hadron Collider, offrendo una finestra unica su fenomeni astrofisici estremi.

Il metodo di ricostruzione noto come Constant Intensity Cut (CIC) ha alla base delle assunzioni fisiche particolari e non sempre vere. Grazie al ML si può correggere questa ricostruzione e vedere dove il modello tipico fallisce.

I raggi cosmici sono particelle cariche, principalmente protoni o nuclei atomici, che bombardano costantemente la Terra provenendo dallo spazio.

La loro origine è un mistero che si infittisce alle energie più estreme. Quando una di queste particelle, con energie superiori a 10^{18} eV, colpisce l'atmosfera terrestre, genera una cascata di miliardi di particelle secondarie nota come "sciame esteso dell'atmosfera".

La loro estrema rarità rende necessario un rivelatore di dimensioni senza precedenti. È qui che entra in gioco l'Osservatorio Pierre Auger, situato nella Pampa Amarilla in Argentina. Con una superficie di 3000 km^2 , è il più grande rivelatore di raggi cosmici al mondo.

La forza dell'osservatorio Auger risiede nel design "ibrido": combina un rivelatore di superficie (Surface Detector, SD), composto da 1660 serbatoi d'acqua distribuiti su una griglia, con un rivelatore a fluorescenza (Fluorescence Detector, FD), che osserva la luce ultravioletta emessa durante lo sviluppo dello sciame in atmosfera.

I dati raccolti da questi detector sono accessibili pubblicamente attraverso il loro portale web. Sono messi a disposizione sia i "raw data" di ogni singolo evento, sia un file di sintesi (summary.csv), contenente eventi sottoposti a selezioni ferree (circa il 10% di quelli raccolti) e con le sole variabili principali.

Il lavoro è stato svolto su quest'ultimo, in particolare sulla parte contenente i dati raccolti dalla griglia di rivelatori distanti 750 *m* l'uno dall'altro (SD750). La densità di stazioni consente una ricostruzione più accurata, riducendo le incertezze dovute a fluttuazioni stocastiche.

Il dataframe contiene 54482 eventi (righe); per ognuno si registrano 72 variabili (colonne), divise in quelle registrate da SD e FD attraverso la dicitura `sd_[nome variabile]`, `fd_[nome variabile]`.

Non tutti gli eventi presentano misure dei due tipi di rivelatori. Quelli che hanno una riga completa sono noti come *Golden Hybrids*. Gli eventi di questo tipo sono di grande valore poiché hanno superato criteri di selezione di ben due classi di rivelatori. In generale possono essere gli eventi di base per una corretta calibrazione dei modelli ML.

Il dataframe è stato ridotto dunque a 31 variabili, le quali sono state suddivise in info (7), variabili del SD (17) ed errori associati alle misure (7).

Tra le variabili del dataframe, la più importante per ricostruire l'energia dei raggi cosmici è `sd_s450`, ovvero la misura del segnale a 450m.

In generale questa variabile diminuisce al variare dell'angolo zenitale, poiché più il raggio è inclinato rispetto alla superficie terrestre, più la sua intensità sarà attenuata.

Per correggerlo, Auger usa il metodo CIC, che si basa sull'idea che il flusso di raggi cosmici sia **isotropo**.

In base a ciò, si costruisce un segnale ideale rispetto ad un angolo di riferimento, da cui poi si costruisce l'energia del primario secondo una legge di potenza.

$$E = A \cdot S^B \quad (1)$$

Il problema principale di questo metodo sta nel fatto che l'assunzione di isotropia fa sì che la correzione sia media; all'aumentare dell'angolo zenitale o della massa del primario, si possono osservare delle anomalie. Proprio qui intervengono i metodi ML.

Selezione Dati - Lateral Distribution Function (LDF)

Il metodo CIC sfrutta la cosiddetta LDF, una funzione che descrive come il segnale degli sciame atmosferici si distribuisce sul terreno in funzione della distanza dall'asse dello sciame. Grazie ad essa si può ricostruire il segnale SD450 anche se nessuna stazione è posizionata esattamente a quella distanza.

Oltre ciò, la LDF fornisce un criterio di selezione di dati. Nel dataframe (sezione errori) sono presenti una colonna contenente il χ^2 della LDF (qualità evento) ed una contenente il numero di gradi di libertà del segnale. Facendo il rapporto tra queste quantità si ottiene un valore che indica la bontà del fit eseguito. Più il valore è vicino ad 1, più l'evento è ben ricostruito. (nel progetto, $\text{ratio} < 2.5$)

Un'altro filtro dei dati è stato eseguito attraverso l'osservazione dell'errore relativo "`sd_ds450/sd_s450`". Se questo supera un certo valore ($\text{ratio} > 2.5$), il segnale a terra risulta poco accurato e viene scartato.

Variabili in gioco

Prima di procedere con l'analisi, osserviamo l'andamento delle variabili principali rispetto all'energia che i modelli vogliono riprodurre.




Figure: Esempi di scatter-plot

Si può notare una relazione quasi del tutto lineare tra l'energia FD ed il logaritmo del segnale. Cosa ben diversa nel caso del coseno, dove non è possibile riconoscere un pattern specifico.

Regressione Lineare - Elastic Net

La prima analisi eseguita sul set di dati è una regressione lineare multivariata utilizzando un insieme di variabili selezionate manualmente in base alla conoscenza fisica del problema.

Essendo nota una legge di potenza, questa è stata "linearizzata" tramite logaritmo. Sono state incluse le seguenti variabili:

- $\log(\text{sd_s450})$ [VEM], ovvero il logaritmo in base 10 del segnale,
- $\cos(\theta)$, con θ [rad] angolo zenitale,
- β e γ , i parametri della LDF

L'obiettivo era quello di costruire un primo modello interpretabile fisicamente.

Successivamente si opta per un modello più rigoroso, che possa selezionare con criterio le migliori variabili per ricostruire l'energia. Il metodo scelto è quello di *Elastic Net* (ENet), ovvero una combinazione di regolatori LASSO che riduce i coefficienti le variabili meno importanti, RIDGE che gestisce le variabili correlate tra loro.

Regressione Lineare - Grafico




Figure: LR & ENet

I risultati dei due metodi sono praticamente uguali. ENet è più restrittivo, riducendo le variabili a segnale e β . I coefficienti dei due modelli sono simili per le variabili in comune.

I modelli lineari non sono in grado di catturare delle relazioni complesse, motivo per cui si è deciso di costruire delle variabili *ingegnerizzate* attraverso quelle selezionate da ENet. In particolare, si sono costruiti i prodotti incrociati come $\cos(\theta) \cdot \log(\text{sd_s450})$ oppure $\cos^2(\theta)$.

Un primo ENet su questo nuovo set di variabili ha permesso di capire quali di queste potessero avere un significato fisico. Successivamente si sono unite le variabili lineari a quelle ingegnerizzate in un'unica regressione regolarizzata.




Figure: Combinazione: manual + ing

Il risultato mostra un miglioramento del R^2 . Le variabili selezionate fanno pensare ad un errore di scelta, dato che ENet per costruzione tende ad attribuire coefficienti simili a variabili simili.

Modelli Lineari - Grafico




Figure: Riassunto dei Modelli Lineari

Osservazioni sulle variabili

Il grafico precedente è giustificato dall'andamento dei seguenti grafici.




Figure: Scatter-plot ingegnerizzati

Si nota dunque che le variabili ingegnerizzate sono troppo simili a quelle scelte manualmente. Con un set di dati piccolo, questo porta ENet a confondere le variabili e selezionarle in maniera errata. Il risultato sarà confermato dai modelli non lineari.

Dai modelli lineari si capisce come il metodo CIC sia effettivamente valido, dato che la variabile principale è sempre il segnale a terra. Non si possono escludere del tutto delle correzioni non lineari come suggerisce il modello a variabili ingegnerizzate.

Notiamo come nel modello combinato, le variabili ingegnerizzate abbiamo dei coefficienti elevati. Questo suggerisce che il loro contributo è piccolo ma esiste.

Il modello lineare è ovviamente la base d'appoggio per modelli più complessi (ML) ma cattura bene la fisica del problema. Il tutto può essere perfezionato attraverso strumenti più complessi, come si vede di seguito.

La regressione lineare (anche con variabili ingegnerizzate) assume che le relazioni siano lineari o trasformabili. La fisica degli sciami potrebbe contenere effetti non lineari più complessi che un modello lineare non può catturare, motivo per cui si decide di procedere con dei modelli che superano questo ostacolo: gli *ensemble methods* (EM).

L'obiettivo finale è correggere l'energia evento per evento. Se la correzione dipende da relazioni complesse tra morfologia, angolo e sviluppo dello sciame, un modello non lineare può catturarle meglio. Per questo progetto si è deciso di usare tre modelli diversi:

- Random Forest.
- Gradient Boosting.
- Extreme Gradient Boosting (XGB).

Il metodo Random Forest si basa sulla creazione di *alberi decisionali* in parallelo, ognuno su un campione casuale dei dati (bootstrap) e su un sottoinsieme casuale delle variabili. La previsione finale è la media (per la regressione) dei risultati di tutti gli alberi.

È un metodo molto usato perché riduce la varianza del campione ed è "robusto" all'overfitting.

Per testare il modello sono state usate sia le variabili scelte manualmente, sia le ristrette attraverso ENet. Inoltre, per verificare l'ipotesi di variabili ingegnerizzate, si è tentato di usare sia queste che la combinazione con le variabili lineari, al fine di osservare o meno un miglioramento del modello.

Random Forest - Grafico




Figure: Confronto tra i fit di Random Forest

Dal grafico si evince che il modello migliore per Random Forest è quello a variabili scelte manualmente. Gli altri fit sono peggiori rispetto ai corrispettivi lineari, suggerendo che la relazione lineare cattura gran parte della fisica rilevante.

Il metodo Gradient Boosting si basa sulla creazione di *alberi decisionali* in sequenza, facendo sì che ogni albero corregga gli errori del precedente. Il tutto si basa sul seguire il gradiente della *funzione di perdita*. Il risultato è un modello altamente preciso, in grado di catturare interazioni complesse.

Per testare il modello sono state usate le stesse variabili del Random Forest, per verificare miglioramenti rispetto ai modelli lineari o al Random Forest stesso.

Gradient Boosting - Grafico




Figure: Confronto tra i fit di Gradient Boosting

Dal grafico si evince che il modello migliore per Gradient Boosting è quello a variabili scelte manualmente. Si può notare un miglioramento rispetto a Random Forest, eccetto per le variabili combinate (modello non buono). L'indice R^2 per ENet raggiunge quasi i livelli della regressione lineare, ma il fatto che sia minore suggerisce che ci sia della correlazione che influisce sul risultato.

Il metodo XGB è una versione migliorata del Gradiente Boosting. Il principio di funzionamento è lo stesso, ma si aggiunge una regolarizzazione simile ad ENet per ridurre l'overfitting. Questa regolarizzazione è accompagnata da una sorta di "potatura" nel caso di alberi complessi che non portano a miglioramenti e da una doppia derivazione (gradiente ed Hessiano). Il tutto rende il modello più veloce ed efficiente.

Il motivo principale per usare XGB in questo caso è verificare se il dataset presenta delle criticità tali da rendere questo modello più valido del normale Gradient Boosting.




Figure: Confronto tra i fit di XGB

Dal grafico si evince che il modello migliore per XGB è quello a variabili scelte manualmente. Gli indici R^2 leggermente minori suggeriscono che il dataset non presenta criticità e che Gradient Boosting basta e avanza per osservare relazioni tra le variabili scelte.

Metodi Ensemble - Grafico




Figure: Risultati dei fit nei Metodi Ensemble

Dalla figura si evince i metodi di ensemble non migliorano rispetto alla regressione lineare, sia come aumento di R^2 che come diminuzione dello scarto quadratico medio (MSE).

Importanza delle Variabili




Figure: Confronto di importanza variabili

Dal seguente grafico possiamo dedurre che la variabile fondamentale per ricostruire l'energia è sempre il segnale a terra. In linea con quanto suggeriscono i modelli lineari, l'altro contributo principale lo fornisce β .

Dall'analisi di tutti i modelli possiamo trarre conclusioni interessanti:

- La regressione lineare, con le variabili selezionate manualmente, coglie già la fisica fondamentale alla base della ricostruzione dell'energia. Il miglioramento ottenuto con le variabili ingegnerizzate non introduce nuova fisica, ma suggerisce la presenza di relazioni non lineari che un modello lineare non può catturare appieno.
- I modelli non lineari non riescono a migliorare molto quanto fatto da ENet, probabilmente a causa di un dataset ristretto. Tuttavia, aiutano a leggere possibili correzioni non lineari e soprattutto a smentire modelli poco coerenti come quello delle variabili ingegnerizzate.

La verifica finale del modello di Machine Learning rispetto al metodo standard CIC si può osservare confrontando una calibrazione CIC sugli eventi *golden hybrids* con il modello Gradient Boosting con variabili selezionate manualmente.

La scelta degli eventi golden deriva dal fatto che in questi sono gli unici eventi per i quali è disponibile l'energia misurata da FD, che rappresenta la "verità" indipendente necessaria per validare la ricostruzione.

Il modello Gradient Boosting presenta un R^2 lineare minore di quello del CIC (-0.7% in log, -12% in lineare), inoltre presenta un grave problema di overfitting nel test ($R^2_{test} = 0.9997$). Probabilmente il metodo ML considera troppe variabili con pochi dati e perde di efficacia.




Figure: Confronto finale

Sviluppi futuri e Miglioramenti

Per migliorare i risultati ottenuti in questa analisi, si potrebbe pensare ad una ricerca a griglia dei migliori parametri associati ai metodi ML. Questo perché ogni modello è governato da iper-parametri diversi, un'operazione di ottimizzazione (*cross-validation*) degli stessi porterebbe a modelli sempre più precisi.

Un altro modo per andare oltre quanto fatto in questo progetto sarebbe quello di costruire delle reti neurali che lavorano direttamente sui dati "grezzi" del rivelatore di superficie (ad esempio le tracce temporali dei segnali nelle singole stazioni, organizzate in griglie spaziali), al fine di ridurre la dipendenza dalla ricostruzione standard e dalla conseguente propagazione degli errori. Questo approccio permetterebbe di bypassare completamente la ricostruzione della LDF (e quindi le variabili derivate come β e γ), consentendo al modello di apprendere autonomamente la morfologia dello sciame.

Grazie per l'attenzione!